

扩散、flow、SDE，从base开始-构建中

第一部分

这部分的文字博客要比视频讲解好在：推导清楚，逻辑清晰，细节深入。看完这些博客，我觉得讲的很清晰，每个点的前提知识都有讲明。

这部分是微信公众号作者孙兵兵2025总结的内容，系统解释了扩散模型的数学和理论基础，不直接从DDPM文章的思路开始，而是从更底层的数学、更通顺的逻辑出发，有比较充分的前提知识。因为公众号的内容写的很好了，我就也不单独复制下来到这里了。灰字是gpt总结的东西，比我写的总结要好，但还是要看原文的推导。

Flow Matching也有讲解，是微信公众号中作者cheern总结的内容。更新较慢，目前最新链接为[生成式AI Lecture 5: Guided flow matching](#)，之后会加入这部分内容。

1. 扩散模型--从布朗运动到维纳过程【SDE的物理与数学基石】

扩散模型起源于布朗运动：1827年布朗发现悬浮微粒的无规则运动，爱因斯坦1905年解释为水分子热运动引起的随机碰撞，这一现象被数学抽象为离散对称随机游走（每步左右等概率、无漂移、方差随步数线性增长），其连续极限是标准维纳过程（满足起点为零、独立平稳正态增量、连续路径等性质），为随机微分方程（SDE）提供了理论基础，并成为现代生成式AI中扩散模型（如DDPM）构建噪声和逆向采样的核心工具。

2. 扩散模型续--拉格朗日与欧拉—描述扩散的两种视角

扩散模型不仅可用拉格朗日视角（跟踪单个粒子的随机轨迹）理解，也可用欧拉视角（研究粒子群体在空间中的浓度演化）描述；爱因斯坦扩散方程用宏观的偏微分方程刻画粒子密度随时间变化，与微观随机游走模型在统计上完全一致，两者统一于更一般的随机微分方程（SDE）和福克-普朗克方程（Fokker-Planck Equation）框架下，构成现代扩散生成模型的数学基础。

宏观上粒子浓度的平滑扩散，其本质是微观上大量粒子独立的、无规则的随机运动的统计表现。

3. 扩散模型续2- 从确定性到随机性——深入理解SDE与ODE的区别与联系【连接 福克-普朗克方程与 刘维尔方程】

扩散模型的核心数学框架连接了确定性与随机性：当随机性消失时，单个粒子的随机微分方程（SDE）简化为确定的常微分方程（ODE），群体概率密度的福克-普朗克方程则退化为仅描述概率守恒运输的连续性（刘维尔）方程；确定性系统表现为无耗散、守恒流动，而随机系统则通过扩散项引入不可逆的熵增，正是这种从确定到随机、从守恒到耗散的对比，揭示了扩散生成模型的本质——学习逆转耗散过程，将随机噪声还原为结构化数据。

连接diffusion与flow matching：SDE变为ODE后，去掉随机项，描述单个粒子运动的通用SDE就变成了flow matching 中的速度；福克-普朗克方程就变成了 刘维尔方程，即连续性方程。

核心对比：确定性系统 vs. 随机系统

现在，我们可以将这两个系统并排放在一起，进行一次详细的对比，以加深理解。

特征	确定性系统 (无随机性)	随机系统 (有随机性)
个体视角	拉格朗日描述	拉格朗日描述
个体路径方程	常微分方程 (ODE) $dx/dt = \mu(x, t)$	随机微分方程 (SDE) $dX_t = \mu(X_t, t) dt + \sigma(X_t, t) dW_t$
群体视角	欧拉描述	欧拉描述
群体分布演化方程	连续性方程 $\partial \rho / \partial t = -\partial (\mu \rho) / \partial x$	福克-普朗克方程 $\partial \rho / \partial t = -\partial (\mu \rho) / \partial x + \partial^2 (D \rho) / \partial x^2$
核心驱动力	仅由漂移场 μ 决定	由漂移场 μ 和 扩散场 σ 共同决定
路径特性	平滑、唯一、可预测	锯齿状、随机、不可预测 (但统计规律可预测)
物理内涵	概率的守恒运输，系统无能量耗散	概率的扩散与漂移，系统是耗散的，熵倾向于增加
与扩散模型关系	描述了数据在无噪声扰动下的确定性变换	描述了数据加噪的“前向过程”和去噪的“反向过程”的理论框架

4. 扩散模型续3-随机微分方程的核心—解密伊藤积分与随机项

本篇深入解析了扩散模型背后的随机微分方程（SDE）核心：维纳过程的无穷小增量 dW_t 具有标准差 $\sqrt{dt}$ ，其随机性主导微观行为；因此在对随机过程做泰勒展开时必须保留二阶项，形成专门的链式法则——伊藤引理（Itô's Lemma），它揭示了随机系统中积分与微分的独特运算规则，并导出了伊藤积分（Itô Integral），这一套工具与经典微积分相比，多出关键的“伊藤修正项”，是理解扩散生成模型、随机优化等机器学习领域方法的数学基石。

5. 扩散模型续4--从噪声到艺术的嬗变

扩散生成模型的核心在于用随机微分方程（SDE）将易采样的简单噪声分布逐步转化为复杂的目标数据分布，通过定义前向加噪过程（已知SDE）与逆向去噪过程（需学习漂移项的SDE），结合数值模拟（如欧拉-丸山法）从噪声中生成高质量样本；训练的关键是学到逆向漂移场，即如何引导噪声逆转移耗回到数据分布，这为扩散模型构建提供了理论与算法的完整框架。

6. 扩散模型续5——时间的逆转：揭秘从图像到噪声的逆向SDE

本篇揭示了扩散模型逆向SDE的数学推导：通过定义一个从数据到噪声的前向SDE（已知可控），利用SDE与福克-普朗克方程的对应关系推导出时间倒流的逆向SDE，其漂移项由前向漂移、扩散系数以及关键的分函数（score function）共同决定，从而将复杂的生成任务转化为学习分函数的可解问题，为扩散模型的训练打下核心理论基础。

利用SDE与福克-普朗克方程的对应关系推导出逆向SDE的方程，得到的公式就是score-sde中的公式，讲解清楚。

7. 扩散模型续6——学习时间逆转的关键：分数匹配

本篇解析了扩散模型训练的核心——分数匹配：由于逆向SDE中关键的分函数（数据对数密度梯度）无法直接计算，扩散模型通过利用正向加噪过程下可计算的条件分数，并证明边缘分数可视为其条件期望，设计出去噪分数匹配（Denoising Score Matching）作为可行的训练目标，使神经网络在均方误差意义下学得逆向漂移场，从而实现从噪声到高质量样本的生成。

本文讲score-matching理论的推导过程，形式和flow matching中的推导过程差不多，都是从加入条件 x_0 来使得便于计算的角度出发的。

8. 扩散模型续7——VP-SDE：从理论到实践的扩散去噪生成魔法

本篇聚焦扩散模型中应用最广的VP-SDE（方差保持SDE），系统梳理其核心机制：通过设计一个方差随时间分解、但总方差保持的前向加噪SDE，将真实图像逐步转换为高斯噪声，并在逆向过程中用神经网络学习分函数，通过去噪分数匹配实现高质量采样；实操中结合U-Net或Transformer架构、欧拉-丸山数值解法和噪声调度优化，VP-SDE为扩散生成模型从理论到实践奠定了高效、可控的实现路径。

9. 扩散模型续8——为生成加速：从随机SDE到确定性ODE实现图像生成的“瞬移”

本篇揭示了扩散模型采样提速的核心思路：通过推导概率流ODE，将原本含随机性的逆向SDE转化为确定性ODE，使生成路径平滑、可预测，并与原SDE保持相同的边缘分布，从而可用大步长或高级ODE求解器（如龙格-库塔）大幅加速采样，显著减少神经网络调用次数；这一理论框架与DDIM等离散确定性采样方法本质一致，为扩散模型高效生成奠定了重要基础。

10. 扩散模型续9——从导航到自驾：驾驭扩散模型的两种引导范式

本篇总结了扩散模型如何实现条件生成：分类器引导（Classifier Guidance）通过外部分类器提供引导梯度，但依赖重、易受噪声干扰；无分类器引导（Classifier-Free Guidance, CFG）则通过在训练时随机置空条件，让同一个模型学会无条件与有条件预测，采样时用两者差值外插构造引导信号，既简洁高效又效果卓越，成为当今文生图等AIGC主流扩散模型的关键技术。

这个是讲diffusion中的guidance的。

11. 扩散模型续10-新篇章【流匹配（Flow Matching）初探】

本篇引入了流匹配（Flow Matching）框架：通过学习一个向量场，用常微分方程（ODE）直接定义从初始噪声分布到目标数据分布的确定性“流”，摆脱SDE中的随机性，实现更通用、高效的生成；核心在于用神经网络拟合这个向量场，并用数值ODE求解器沿流采样生成，下一步的关键则是设计损失函数，让模型学会预测正确的流动方向。

Flow matching 的开头

未完待续